En algebra av ideer

Jan Arne Telle, professor i algoritmer
institutt for informatikk, universitetet i Bergen

Språkmodellene har lært mye mer enn å fullføre setninger. KI-sikkerhet handler også om å forstå hva de har lært, og hvordan det virker.

Gjennom de siste årene har vi klart å trene kunstig intelligens til å gjøre stadig mer komplekse oppgaver. Vi skjønner fort hvordan vi skal bruke disse store språkmodellene, men når vi skal utarbeide rammeverk for KI-sikkerhet trenger vi å forstå hva som foregår inne i dem når de utfører oppgaver, ellers kan vi ikke ha håp om å styre dem. Dette er et forskningsområde som får besynderlig lite oppmerksomhet og hvor norske forskningsmiljøer trenger et løft. For mellom begeistringen og bekymringen rundt KI-sikkerhet er det et viktig spørsmål som fort forsvinner: hvordan virker egentlig disse systemene? Standardsvaret er at de gjetter neste ord. Det er ikke feil, men som forklaring minner det om å beskrive mennesket som et vesen formet av evolusjonen til å føre genene videre. Det sier noe vesentlig om hvordan vi ble til, men forklarer ellers lite.

1 Fra ord til geometri

En språkmodell trenes blant annet ved å forsøke å forutsi neste tekstbit i en gitt tekst. Tekstbiten kan være et ord, en del av et ord eller et tegn. Modellen gjør feil, og et enormt antall interne tallverdier justeres slik at antall feil blir litt mindre. Dette gjentas i en nesten ufattelig skala. Selv med en milliard regneoperasjoner i sekundet ville en sekvensiell trening av en stor språkmodell tatt over hundre millioner år. I praksis gjøres disse beregningene parallelt.

Det å forutsi neste tekstbit kan virke som en beskjeden oppgave. Men tenk over hva som kan være nyttig å lære for å løse den godt. For å fullføre en kriminalroman må man holde orden på hvem som vet hva, og helst være kreativ. For å fortsette et matematisk bevis må man fange opp alle logiske sammenhenger, og igjen vil kreativitet belønnes. For å skrive neste replikk i en komedie hjelper det å ha lært noe om menneskelige forventninger – og hvordan de kan skuffes på en tilfredsstillende måte. Å forutsi tekst fører derfor til langt mer enn pugging av ordrekkefølger. Det fører til interne representasjoner av sammenhengene teksten handler om. Det betyr ikke at modellen alltid resonnerer riktig, eller at den forstår som oss, men treningsoppgavens enkelhet må ikke forveksles med enkelhet i det som læres. Inne i modellen behandles teksten som vektorer: lister

med tall i rom med tusenvis av dimensjoner. Gjennom lag på lag av beregninger endres disse representasjonene, og informasjon fra ulike deler av teksten kombineres.

En mer fruktbar metafor enn 'gjetting av neste ord' er derfor 'en algebra av ideer', altså en matematisk håndtering av ideene som ligger i teksten som produseres. I denne algebraen kommer mening til uttrykk som retninger eller vektorer i et høydimensjonalt rom hvor man kan utføre algebraiske operasjoner. For eksempel vil 'mann'-'kvinne'+'tante' gi noe noe som er veldig nær 'onkel', hvilket innebærer at retningen gitt av 'mann'-'kvinne' er den samme som 'onkel'-'tante' og representerer kjønn. Samtidig vil en formulering få en annen representasjon når den står i en annen sammenheng. En 'pris' i en butikk og en 'pris' i en konkurranse havner ikke på samme sted i betydningslandskapet. Ord og setninger omformes til kontinuerlige vektorrepresentasjoner i høydimensjonale, semantiske rom, der mening er kodet i geometrien: begreper blir retninger, kategorier blir klynger, og resonnering utfolder seg gjennom vektortransformasjoner. Først i utdatalaget omdannes representasjonene tilbake til ord og tekst. Metaforen flytter oppmerksomheten dit den bør være: fra ordene som kommer ut, til representasjonene og beregningene som gjør dem mulige.

2 En algebra som har vokst frem

Og nettopp her ligger det forunderlige: denne algebraen er ikke skrevet av programmererne. Forskerne og ingeniørene har laget arkitekturen, valgt treningsopplegget og bygget infrastrukturen. Men de har ikke bestemt hvordan modellen skal representere sarkasme eller håndtere et matematisk bevis. De indre løsningene har vokst frem gjennom trening. KI-forskeren Richard Sutton snakket om 'den bitre lærdommen': generelle metoder som utnytter stor beregningskraft har over tid vist seg å være mer fruktbare enn forsøk på å bygge menneskelig ekspertkunnskap direkte inn i systemene. Vi har fått større fremgang ved å forbedre læringen og skalere beregningene enn ved å fortelle maskinen alt vi mener den bør vite. Det er en bitter lærdom for ekspertene, og en viktig forklaring på de enorme treningskostandene til KI-labene.

Språkmodeller er både bygget og dyrket frem. Ingeniørene lager veksthuset. Treningen avgjør mye av det som vokser der. Vi kjenner regnereglene og kan undersøke modellens tallverdier. Likevel mangler vi en forklaring på de fleste innlærte mekanismene. Å ha tilgang til alle tallene er ikke det samme som å forstå hva de gjør sammen. Det er forskjell på å kunne lese av hver eneste verdi i en maskin og å vite hvorfor maskinen nettopp foreslo noe katastrofalt.

3 Å åpne modellen

Fagfeltet som forsøker å redusere dette gapet, heter mekanistisk tolkbarhet. Navnet er tungt. Oppgaven er mye tyngre. Forskerne vil identifisere interne mekanismer og undersøke hvordan de frembringer en bestemt respons. Her er

det viktig å holde tungen rett i munnen; forskerne ønsker nemlig ikke bare å spørre modellen hvorfor dette var responsen (et velformulert svar på dette spørsmålet er nemlig ingen garanti for en korrekt forklaring) men å studere og ikke minst påvirke selve beregningene.

Et mye omtalt forsøk fra Anthropic illustrerer dette. Forskerne identifiserte en intern vektor knyttet til Golden Gate-broen. Da de skrudde opp betydningen av denne vektoren, begynte modellen å trekke Golden Gate-broen inn i svar på spørsmål som handlet om helt andre ting. Da den for eksempel skulle gi spaghetti-oppskrift, foreslo den at man brukte hermetikk-tomater fra et bestemt merke, siden disse boksene hadde den samme rødfargen som Golden Gate-broen. Modellen hadde fått en slags digital kjepphest. Forsøket viser at det er mulig å finne meningsfulle interne vektorer og påvirke atferden gjennom dem. Det store målet er å påvirke i retning av atferd som gagner menneskeheten.

Utfordringene er store og uhyrlig komplekse. Mange trekk kan være pakket inn i samme dimensjon, noe som kalles distribuert representasjon. I tillegg har vi det som kalles superposisjon som gjør at modellen kan pakke inn flere trekk enn det er dimensjoner i representasjonen. Det er plassbesparende, men gjør det vanskeligere for forskerne å skille trekkene fra hverandre. I tillegg endrer representasjonene seg gjennom modellens lag, og det er kun i utdata-laget alt blir omgjort til et enkelt 'neste ord'. Trekkene modellen har lært behøver heller ikke følge våre begrepsgrenser. Vi kan ikke gå ut fra at modellen har sortert verden i de samme skuffene som oss.

4 En norsk oppgave

Dette blir viktigere når språkmodeller ikke bare svarer, men handler. Koblet til verktøy kan de søke på nettet eller legge ting ut på nettet, skrive og kjøre kode og utføre oppgaver over mange trinn. Da kan en svakhet i modellen forplante seg fra en formulering til en handling. Regulering og tilgangskontroll er nødvendige. Mekanistisk tolkbarhet erstatter ingen av delene. Full forståelse er heller ingen forutsetning for enhver nyttig anvendelse. Men kunnskap om de indre mekanismene kan gjøre sikkerhetsarbeidet mindre avhengig av at vi tilfeldigvis har testet akkurat den situasjonen der det går galt. Norge bør derfor etablere en langsiktig forskningssatsing på mekanistisk tolkbarhet. Den må gi universitetsmiljøer forskerstillinger, regneressurser og tilgang til modeller som kan undersøkes innvendig. Vi kan utvikle bedre metoder for å undersøke modellene, prøve om forklaringer holder, og kartlegge når tiltak virker – og når de bare flytter problemet. Noe av dette gjøres allerede av selskapene som utvikler modellene. Det er bra, men ikke tilstrekkelig. Samfunnet trenger kompetanse som kan etterprøve leverandørene, ikke bare gjengi presentasjonene deres. Norsk KI-politikk kan ikke nøye seg med å spørre hvordan vi tar teknologien i bruk, eller hvilke regler bruken skal følge. Den må også spørre hvilken kunnskap vi trenger for at kravene vi stiller kan følges opp.

Vi har fått maskiner med en algebra av ideer vi ikke selv har skrevet. Da bør vi investere i å lære å lese den.